

Algoritmi-Modulo algoritmi per bioinformatica

Problema della mediana (statistiche d'ordine)-Capitolo 9 CLRS

Roberto Posenato

versione 2026-1, 19/03/2026

- 1 Mediane e statistiche d'ordine
 - Idea generale
 - Mediana

*“Tell me and I forget, teach me and I remember,
involve me and I learn.”*

Benjamin Franklin

*“A student who achieves knowledge through free investigation
and spontaneous effort will be able to retain that knowledge
and will have acquired a methodology that can serve for a li-
fetime.”*

Jean Piaget

Scopo della lezione

- Proporre un altro esempio di problema importante che ammette soluzione algoritmica *divide et impera* di buona qualità nel caso medio: problema delle statistiche d'ordine.

Statistiche d'ordine

Idea generale

Definizione 1 (Statistica d'ordine)

Dato un insieme di n elementi,

- la **i -esima statistica d'ordine** è l' i -esimo elemento più piccolo.

Esempio 1 (Statistica d'ordine)

Dato l'insieme $\{3, 5, 9, 4, 6, 1\}$ di $n = 6$ elementi,

- la **I statistica d'ordine** è 1 (elemento minimo)
- la **VI statistica d'ordine** è 9 (elemento massimo)
- la **IV statistica d'ordine** è 5.

Statistiche d'ordine

Mediana

Definizione 2 (Mediana)

Rappresenta un valore v tale che almeno il 50% degli elementi è $\leq v$ e almeno il 50% è $\geq v$:

- se n è dispari, la mediana è la $(n + 1)/2$ statistica d'ordine;
- se n è pari, le mediane possono essere due: la statistica d'ordine $i = n/2$ e la statistica d'ordine $n/2 + 1$.
- Si preferisce dire che, a prescindere dalla parità di n , ci sono:
 - **mediana inferiore**: statistica d'ordine $\lfloor (n + 1)/2 \rfloor$
 - **mediana superiore**: statistica d'ordine $\lceil (n + 1)/2 \rceil$
- Se si scrive **mediana** solo, si intende **mediana inferiore**.

Esempio 2

Dato l'insieme $\{3, 5, 9, 4, 6, 1\}$ di $n = 6$ elementi,

- **mediana inferiore**: III statistica d'ordine è 4.
- **mediana superiore**: IV statistica d'ordine è 5.

PROBLEMA SELEZIONE

INPUT: Un insieme A di n numeri (distinti) e un intero $1 \leq i \leq n$.

OUTPUT: Determinare l' i -esimo elemento più piccolo di A .

- **Selezione** si può risolvere in tempo $\Theta(n \log n)$ ordinando gli elementi.
- Ma non ha senso dover ordinare/spostare gli elementi quando si vuole conoscere solo qual è la i -esima statistica d'ordine.
- In questa lezione vediamo come è possibile risolvere il problema SELEZIONE in tempo atteso $O(n)$.

[CLRS] assume che i numeri siano distinti per comodità. Si può dimostrare in seguito che i risultati sono validi anche quando i numeri non sono distinti.

Statistiche d'ordine

Problema della selezione della prima o ultima statistica d'ordine

- Trovare il minimo o il massimo è facile.

Algoritmo: MINIMUM(A)

Input: Array $A[1 : n]$

Output: Valore minimo $m \in A$

```
1:  $m = A[1]$ 
2: for  $i = 2$  to  $n$  do
3:   if  $m > A[i]$  then  $m = A[i]$ 
4: return  $m$ 
```

- Richiede $n - 1$ confronti.
- Il tempo di computazione è quindi $\Theta(n)$.
- È ottimale rispetto al numero di confronti: ogni elemento, tranne il minimo, deve confrontarsi con almeno un elemento per stabilire che non è il minimo. Quindi ci sono almeno $n - 1$ confronti da fare.
- L'algoritmo MAXIMUM(A) è analogo (basta cambiare $>$ con $<$).

Statistiche d'ordine

Problema min e max insieme

- Trovare il minimo e il massimo contemporaneamente.
- Fondendo MINIMUM(A) e MAXIMUM(A), si può risolvere il problema con $2(n - 1)$ confronti.
- Si può risolvere il problema con $\lceil \frac{3n}{2} \rceil - 2$ confronti.
- Si devono confrontare gli elementi a coppie anziché singolarmente.

Algoritmo: MINMAX(A)

Input: Array $A[1 : n]$

Output: Valori minimo e massimo $(m, M) \in A$

```
1: if  $n \% 2 \neq 0$  then //  $n$  è dispari
2:   |    $m = M = A[1]$ 
3:   |    $i = 2$ 
4: else
5:   |   if  $A[1] < A[2]$  then  $m = A[1]; M = A[2]$ 
6:   |   else  $M = A[1]; m = A[2]$ 
7:   |    $i = 3$ 
8: while  $i \leq n - 1$  do
9:   |   // Completare: usare  $(A[i], A[i + 1])$  per aggiornare  $m$  e  $M$ 
9: return  $(m, M)$ 
```

Statistiche d'ordine

Idea *divide et impera*

L'idea *divide et impera* per risolvere il problema SELEZIONE(A, i) è la seguente:

- Dato un numero (casuale) v di A , si suddivide A in 3 sottoinsiemi:

① $A_L = \{x \in A \mid x < v\};$

② $A_V = \{x \in A \mid x = v\};$

③ $A_R = \{x \in A \mid x > v\};$

- la ricerca del i -esimo elemento più piccolo può essere quindi ristretta come:

$$\text{SELEZIONE}(A, i) = \begin{cases} \text{SELEZIONE}(A_L, i) & i \leq |A_L| \\ v & |A_L| < i \leq |A_L| + |A_V| \\ \text{SELEZIONE}(A_R, i - |A_L| - |A_V|) & i > |A_L| + |A_V| \end{cases}$$

- Le tre liste si determinano con un numero di confronti $\Theta(n)$.
- Dato A , la dimensione del sottoproblema è $\leq \max\{|A_L|, |A_R|\}$

Statistiche d'ordine

Esempio

Esempio 3 (Funzionamento *divide et impera* per SELEZIONE($A, \frac{n}{2}$))

Dato l'insieme $\{3, 5, 9, 4, 6, 1\}$ di $n = 6$ elementi, il problema della mediana è il problema SELEZIONE($A, 3$):

- Un valore casuale di A **accade** che sia 3:
 - $A_L = \{1\}$
 - $A_3 = \{3\}$
 - $A_R = \{5, 9, 4, 6\}$
- Vale $3 > |A_L| + |A_3|$ (infatti $3 > (1 + 1)$)
- Si deve risolvere
 $\text{SELEZIONE}(A_R, 3 - |A_L| - |A_3|) = \text{SELEZIONE}(\{5, 9, 4, 6\}, 1)$
- Un valore casuale di $\{5, 9, 4, 6\}$ **accade** che sia 4:
 - $A_L = \{\}$
 - $A_4 = \{4\}$
 - $A_R = \{5, 9, 6\}$
- Vale $|A_L| < 1 \leq |A_L| + |A_4|$ ($0 < 1 \leq (0 + 1)$)
- La mediana (soluzione) è 4.

Statistiche d'ordine

Mediana: pseudocodifica Capitolo 9.2 di [CLRS]

Questa implementazione riusa $\text{RANDPARTITION}(A, p, r)$ vista per QuickSort. **Versione del Corman che assume tutti valori distinti!**

Algoritmo: $\text{RANDSELECT}(A, p, r, i)$

```
1: if  $p == r$  then return  $A[p]$ 
2:  $q = \text{RANDPARTITION}(A, p, r)$ 
3:  $k = q - p + 1$ 
4: if  $i == k$  then return  $A[q]$ 
5: if  $i < k$  then
6:   return  $\text{RANDSELECT}(A, p, q-1, i)$ 
7: else
8:   return  $\text{RANDSELECT}(A, q+1, r, i-k)$ 
```

Algoritmo: $\text{RANDPARTITION}(A, p, r)$

```
1:  $i$  = valore casuale tra  $p$  e  $r$ 
2: Scambia  $A[r]$  con  $A[i]$ 
3: return  $\text{PARTITION}(A, p, r)$ 
```

Algoritmo: $\text{PARTITION}(A, p, r)$

```
1:  $x = A[r]$ 
2:  $i = p - 1$ 
3: for  $j = p$  to  $r - 1$  do
4:   if  $A[j] \leq x$  then
5:      $i = i + 1$ 
6:     Scambia  $A[i]$  con  $A[j]$ 
7: Scambia  $A[i + 1]$  con  $A[r]$ 
8: return  $i + 1$ 
```

Statistiche d'ordine

Selezione: esempio

		p	r	i	partitioning	helpful?																															
$A^{(0)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>6</td><td>19</td><td>4</td><td>12</td><td>14</td><td>9</td><td>15</td><td>7</td><td>8</td><td>11</td><td>3</td><td>13</td><td>2</td><td>5</td><td>10</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	6	19	4	12	14	9	15	7	8	11	3	13	2	5	10	1	15	5			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
6	19	4	12	14	9	15	7	8	11	3	13	2	5	10																							
					1	no																															
$A^{(1)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>6</td><td>4</td><td>12</td><td>10</td><td>9</td><td>7</td><td>8</td><td>11</td><td>3</td><td>13</td><td>2</td><td>5</td><td>14</td><td>19</td><td>15</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	6	4	12	10	9	7	8	11	3	13	2	5	14	19	15	1	12	5			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
6	4	12	10	9	7	8	11	3	13	2	5	14	19	15																							
					2	yes																															
$A^{(2)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>3</td><td>2</td><td>4</td><td>10</td><td>9</td><td>7</td><td>8</td><td>11</td><td>6</td><td>13</td><td>5</td><td>12</td><td>14</td><td>19</td><td>15</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	3	2	4	10	9	7	8	11	6	13	5	12	14	19	15	4	12	2			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
3	2	4	10	9	7	8	11	6	13	5	12	14	19	15																							
					3	no																															
$A^{(3)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>3</td><td>2</td><td>4</td><td>10</td><td>9</td><td>7</td><td>8</td><td>11</td><td>6</td><td>12</td><td>5</td><td>13</td><td>14</td><td>19</td><td>15</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	3	2	4	10	9	7	8	11	6	12	5	13	14	19	15	4	11	2			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
3	2	4	10	9	7	8	11	6	12	5	13	14	19	15																							
					4	yes																															
$A^{(4)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>3</td><td>2</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>11</td><td>9</td><td>12</td><td>10</td><td>13</td><td>14</td><td>19</td><td>15</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	3	2	4	5	6	7	8	11	9	12	10	13	14	19	15	4	5	2			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
3	2	4	5	6	7	8	11	9	12	10	13	14	19	15																							
					5	yes																															
$A^{(5)}$	<table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td><td>11</td><td>12</td><td>13</td><td>14</td><td>15</td></tr><tr><td>3</td><td>2</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>11</td><td>9</td><td>12</td><td>10</td><td>13</td><td>14</td><td>19</td><td>15</td></tr></table>	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	3	2	4	5	6	7	8	11	9	12	10	13	14	19	15	5	5	1			
1	2	3	4	5	6	7	8	9	10	11	12	13	14	15																							
3	2	4	5	6	7	8	11	9	12	10	13	14	19	15																							

Statistiche d'ordine

Selezione: scelta di $A[q]$

Ma è quello che cerchiamo!

Aspetto cruciale: come scegliere $A[q]$.

- Se $A[q]$ è scelto sempre in modo che $|A_L| \approx |A_R| \approx \frac{1}{2}|A|$
 $\Rightarrow T(n) = T(\frac{n}{2}) + \Theta(n) = \Theta(n)$.
- Il caso peggiore è quando $A[q]$ è sempre l'elemento massimo:
 $\Rightarrow T(n) = T(n-1) + \Theta(n) = \Theta(n^2)$.
- Che valore assume il caso medio nell'intervallo $[\Theta(n), \dots, \Theta(n^2)]$?
- Assumere il caso medio è sensato nella pratica?
- Serve un po' di calcolo delle probabilità...

Esempi di applicazione

Selezione: distribuzione di $A[q]$

Definiamo $A[q]$ **buono** se risiede tra il 25° e il 75° percentile*.

- $A[q]$ è **buono** $\Rightarrow |A_L|, |A_R| \leq \frac{3}{4}|A|$.
- 50% di A sono elementi **buoni**.
- Sia X_v la variabile casuale indicatrice: v è un elemento buono.
- $\Pr\{X_v = 1\} = E[X_v] = \frac{1}{2}$
- Se scelgo due elementi $A[q]$ e $A[q']$ casualmente (uno dopo l'altro), il valore atteso del totale di elementi buoni è
$$E[X_{A[q]} + X_{A[q']}] = E[X_{A[q]}] + E[X_{A[q']}] = \frac{1}{2} + \frac{1}{2} = 1$$
- Quindi, dopo un numero atteso pari a 2 di scelte casuali di v si ottiene un valore **buono**[†] $\Rightarrow$ dimensione dell'istanza diminuisce di almeno $\frac{1}{4}$.

*Il j -percentile è il minimo valore sotto al quale ricade il $j\%$ degli elementi considerati.

[†][CLRS] ... si ha una partizione **utile**

Esempi di applicazione

Selezione: complessità nel caso medio

La complessità **media** dell'algoritmo RANDSELECT può essere calcolata come:

- Sia $s(n) = \Theta(n)$ il costo di una chiamata a RANDPARTITION.
- Sia $w(n)$ il costo totale delle chiamate a RANDPARTITION fino a ottenere un valore **buono** per $A[q]$; allora $E[w(n)] = O(n)$.
- La complessità **media** soddisfa quindi

$$E[T(n)] \leq E\left[T\left(\frac{3}{4}n\right)\right] + O(n)$$

- Per sostituzione si ottiene $E[T(n)] = O(n)$.
- Inoltre $E[T(n)] = \Omega(n)$, perché almeno una partizione completa va sempre eseguita.
- Quindi $E[T(n)] = \Theta(n)$.

- **RANDSELECT** risolve il problema **SELEZIONE** usando **RANDPARTITION** che ha il vantaggio di non richiedere memoria ausiliaria ma ha lo svantaggio che altera l'ordine originale dell'array d'input.

In questa lezione si è visto:

- Cosa sono le statistiche d'ordine.
- Come calcolare le statistiche di primo e ultimo ordine in tempo lineare.
- Come calcolare la statistica d'ordine arbitrario (con particolare enfasi sulla mediana) in tempo medio $\Theta(n)$ con un algoritmo *randomizzato*.
- Come fare un'analisi di complessità per un semplice algoritmo randomizzato.

- Studiare Capitolo 9 fino a 9.3 escluso [CLRS].
- Completare l'algoritmo MINMAX.
- Riscrivere la RANDSELECT() assumendo che ci siano anche elementi uguali.
- Risolvere gli esercizi 9.1-1, 9.2-1, 9.2-2, 9.3-6, 9.3-8 [CLRS].
- Determinare un algoritmo (con complessità media $\Theta(n \lg n)$) per il seguente problema:

PROBLEMA ELIMINAZIONE DUPLICATI IN UN ARRAY

INPUT: Un array di n elementi confrontabili.

OUTPUT: Eliminare eventuali duplicati.